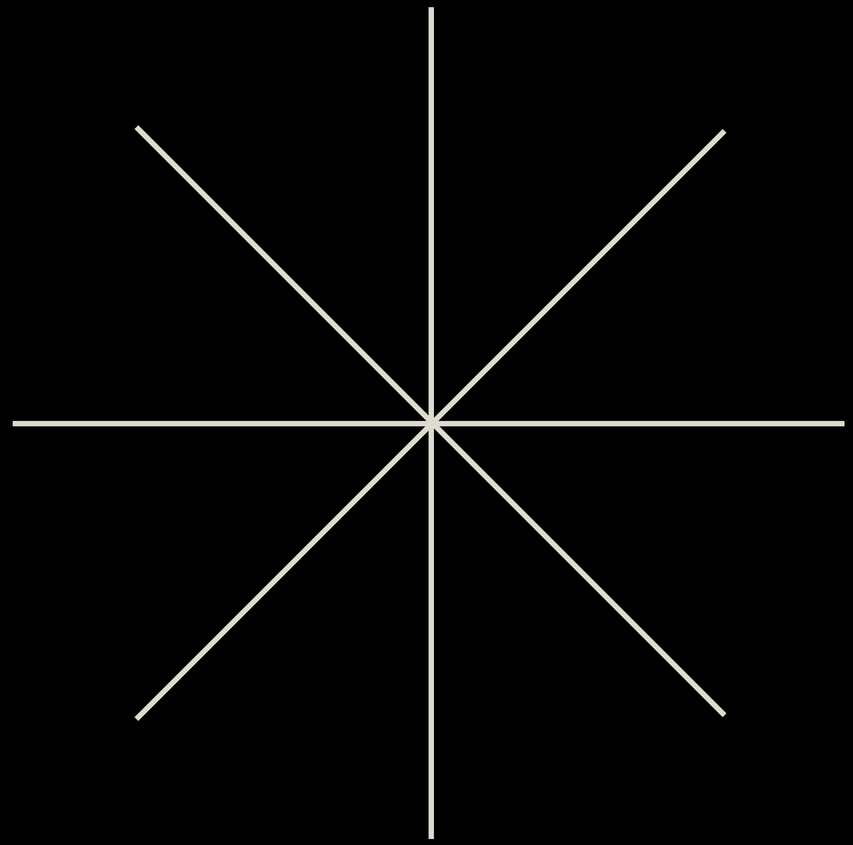
AI B2B SAS 67

ML — Ярослав Лихачев
Разработчик — Пшенников Данила Максимович



НЕЙРО-СТЕНОГРАФИСТ

Архитектура, модели и результаты Android-приложения

Специализированные модели. Локальный LLM.

АУДИО — VAD

Моно 16 кГц
Silero + тихая речь

ASR

GigaAM v3 — русский
Parakeet — английский

ДИАРИЗАЦИЯ

Точки смены — эмбеддинги
говорящие по фразам

ALIGNER — JSON

Слова + говорящий
начало и конец реплики

ПОСЛЕ СОХРАНЕНИЯ JSON — QWEN3 / LLAMA.CPP

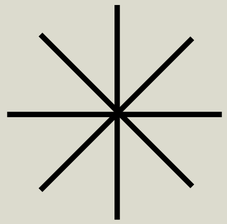
Протокол, выжимка, ответы по расшифровке

Выбор моделей: качество, память и язык

РОЛЬ	МОДЕЛЬ	ПОЧЕМУ
Речь / язык	Silero VAD / Whisper-tiny	Паузы и язык по фрагментам
ASR	GigaAM v3 / Parakeet-110m	Русский со знаками / английский
Говорящие	pyannote-3.0 + 3D-Speaker	Смена голоса + эмбеддинг фразы
Локальный LLM	Qwen3 / llama.cpp	Протокол, выжимка, ответы

Synth test, WER со знаками: 30,8% против 45,9% у RNNT без пунктуации.
ASR ставит знаки без отдельного прохода LLM.

Говорящий определяется по фразе



24,0%

11,7%

DER / ДО И ПОСЛЕ

Сначала слова.
Затем — чей это голос.

Эмбеддинг каждой фразы
— кластеризация Ward
— сборка реплик

Число говорящих определено верно:
41,9% — 77,4% записей

Локальная Qwen3 после сохранения JSON

ГОТОВЫЙ JSON

Текст
Говорящие
Временные метки

Исходные реплики сохраняются отдельно.

QWEN3 НА УСТРОЙСТВЕ

01 Протокол и выжимка

02 Вопросы по разговору

03 Поиск с переходом к реплике

Ответ можно сверить с исходной репликой. Вывод LLM требует проверки.

Что именно измеряли

84 DEV

Подбор параметров

31 TEST

Отложенная проверка
в ПК-эталоне Medium

WER = (замены + удаления + вставки) / слова

DER — ошибка говорящего по времени, допуск ±0,25 с

RTF = время обработки / длительность аудио

Тестовые диалоги: склейки чтения и TTS. Реальные беседы не размечены.

Измерили на реальном Pixel 10

20,26%

WER · ошибки в словах

13,11%

DER · ошибки диаризации

HARD 0.1.0 · 3 СИНТЕТИЧЕСКИХ ДИАЛОГА
Дальнее поле, телефон, шум. Метрики с микроусреднением.

ОТДЕЛЬНЫЙ ПРОГОН В РЕЖИМЕ ПОЛЁТА

9,04 с обработки · RTF 0,277 · JSON валиден

Быстрее длительности записи

0,144

RTF = обработка / длительность аудио

Среднее по шести записям

≈6,9×

быстрее реального времени

735 МБ

максимальный пик PSS

MEDIUM · PIXEL 10 · 6 ЗАПИСЕЙ · ОСНОВНОЙ ПАЙПЛАЙН БЕЗ LLM

ДИАПАЗОН RTF 0,09–0,22 · ВСЕ 6 JSON ПРОШЛИ ПРОВЕРКУ СХЕМЫ

Ограничения: перекрытия и число говорящих

ОГРАНИЧЕНИЕ	ЧТО УЛУЧШАТЬ
Одновременная речь	Разделять перекрывающиеся голоса
Нестабильное число говорящих	Настроить пороги на реальных беседах
Тесты: склейки и TTS	Собрать размеченные живые разговоры

Короткие «да/угу» могут теряться. GPU/NPU пока не используются.